I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-1
Profesor: Pablo A. Deossa M.

INFORME
Evaluación práctica de la Unidad 1: Reconociendo lo aprendido

Grupo 5
Miembros
Cristian Camilo Hernandez Lopez
Juan Felipe Serna Bedoya
Mydshell Stephannia Usuga Arango

Caso de Estudio: Empresa "Gaseosas Poderosas"

En base a la información suministrada, debe construir un modelo conceptual y un modelo lógico de base datos que represente el Caso de Estudio, realizar todo el proceso ETL, limpieza, visualización y análisis de los resultados. Cada sección a continuación especifica las instrucciones para realizar la actividad.

1.- Descripción de la Tarea

El trabajo consiste en diseñar e implementar un proceso ETL o de extracción, transformación y carga para una empresa llamada "Gaseosas Poderosas". El objetivo es migrar la información de ventas, que actualmente está dispersa en archivos de Excel, hacia una base de datos relacionada. Con esto se pretende eliminar la redundancia y la contaminación de los datos, permitiendo que la empresa tome decisiones reales basadas en análisis de Big Data.

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-1
Profesor: Pablo A. Deossa M.

2.- Diagrama de Entidad -Relación (Diagrama de Chen)

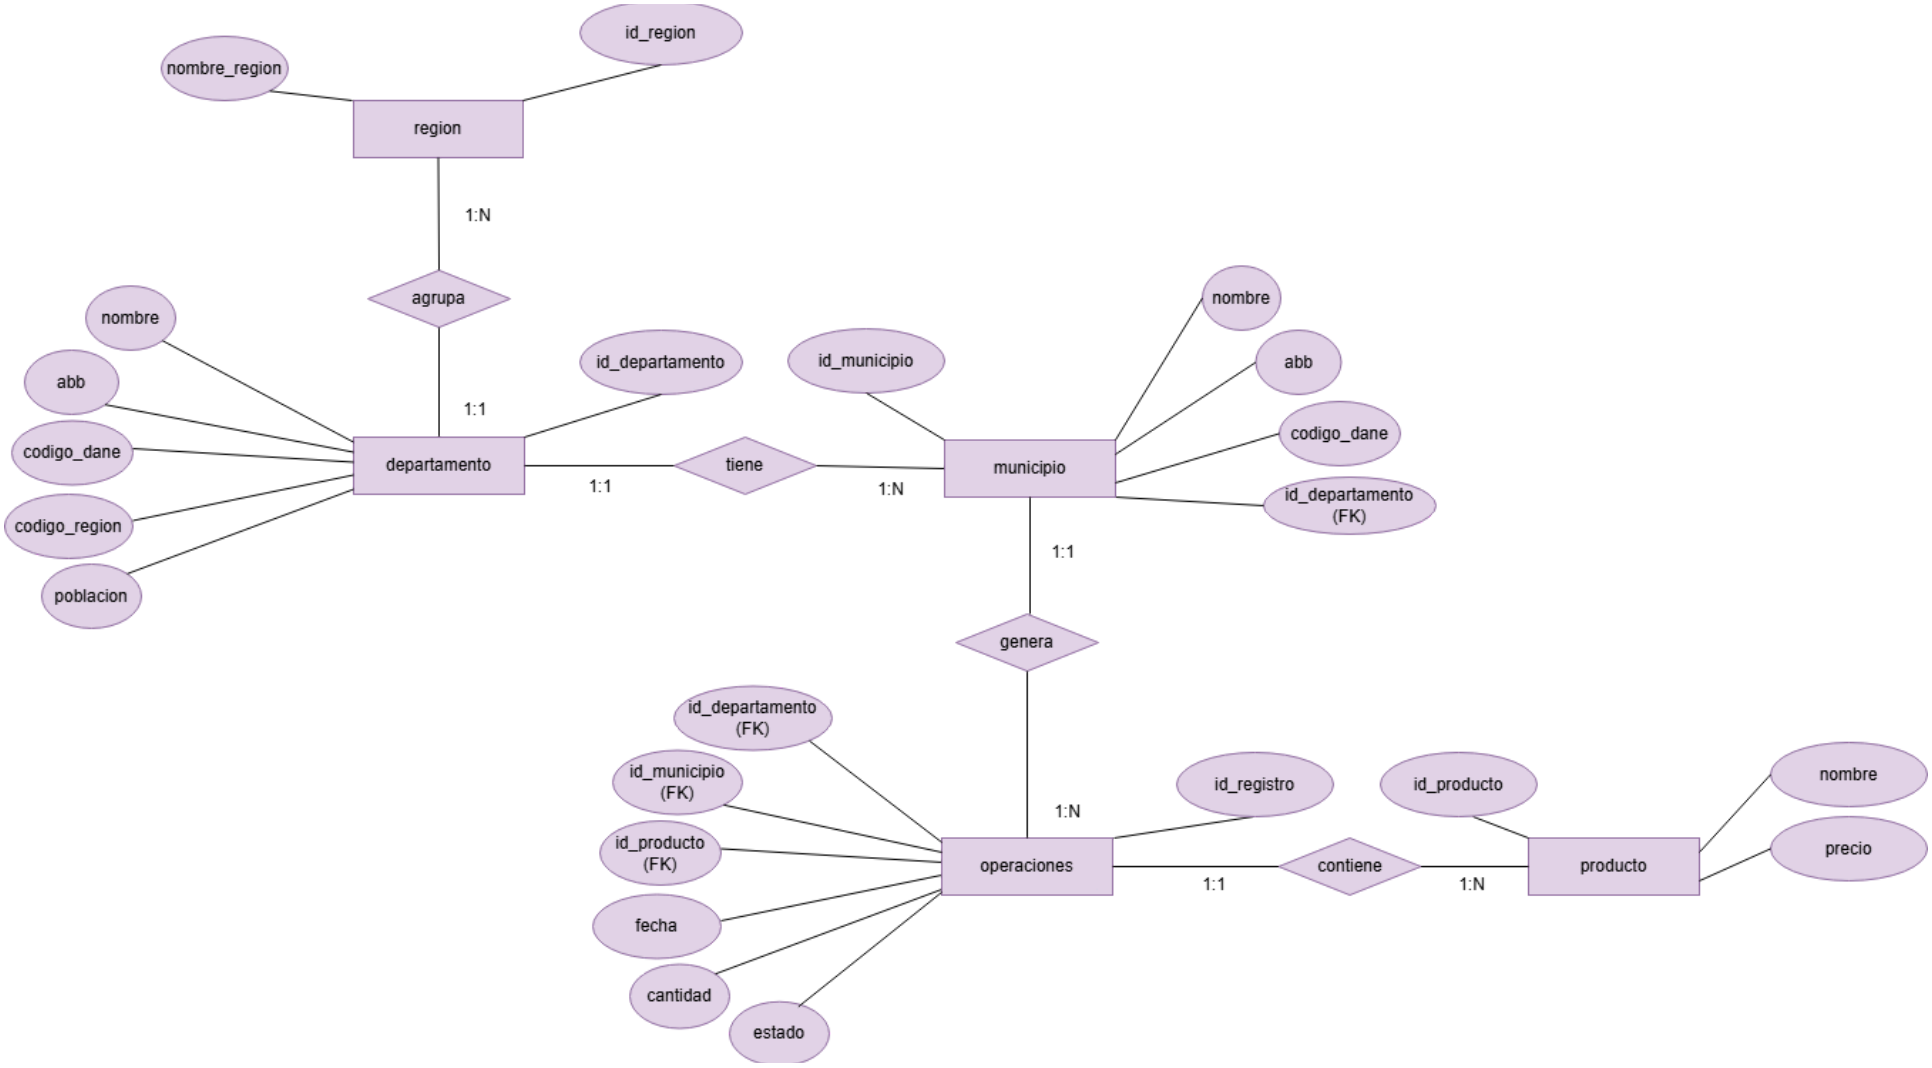

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-1
Profesor: Pablo A. Deossa M.

3.- Diccionario de Datos

1	Tabla	region	Descripción Tabla	Contiene la información de las regiones del país.					Versión	1
#	**Campo**	**Descripción Campo**	**Tipo Dato (Genérico)**	**Tamaño / Longitud**	**Nulo**	**PK**	**FK**	**UK**	**Nota/Comentarios**	
1	id_region	Identificador único de la región	INTEGER	6	NO	SI			Dato obligatorio	
2	nombre_region	Nombre de la región	VARCHAR	50	NO				Ninguno	

2	Tabla	departamento	Descripción Tabla	Contiene la información de los departamentos del país.					Versión	1
#	**Campo**	**Descripción Campo**	**Tipo Dato (Genérico)**	**Tamaño / Longitud**	**Nulo**	**PK**	**FK**	**UK**	**Nota/Comentarios**	
1	id_departamento	Identificador único del departamento	INTEGER	6	NO	SI			Dato obligatorio	
2	nombre	Nombre del departamento	VARCHAR	50	NO				Ninguno	
3	abb	Abreviatura del departamento	VARCHAR	4	NO				Ninguno	
4	codigo_dane	Código único del departamento según DANE	INTEGER	6	NO				Ninguno	
5	codigo_region	Código único de la región según el DANE	INTEGER	6	NO		SI		FK hacia region	
6	poblacion	Cantidad de habitantes del departamento	INTEGER	10	NO				Ninguno	

3	Tabla	municipio	Descripción Tabla	Contiene la información de los municipios del país.					Versión	1
#	**Campo**	**Descripción Campo**	**Tipo Dato (Genérico)**	**Tamaño / Longitud**	**Nulo**	**PK**	**FK**	**UK**	**Nota/Comentarios**	
1	id_municipio	Identificador único del municipio	INTEGER	6	NO	SI			Dato obligatorio	
2	id_departamento	Identificador único del departamento	INTEGER	6	NO		SI		FK hacía departamento	
3	nombre	Nombre del municipio	VARCHAR	50	NO				Ninguno	
4	abb	Abreviatura asignada al municipio	VARCHAR	4	NO				Ninguno	
5	codigo_dane	Código único del municipio según DANE	INTEGER	6	NO				Ninguno	

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-1
Profesor: Pablo A. Deossa M.

4	**Tabla**	**producto**	**Descripción Tabla**	**Contiene la información de los productos que comercializa la empresa.**					**Versión**	**1**
#	**Campo**	**Descripción Campo**	**Tipo Dato (Genérico)**	**Tamaño / Longitud**	**Nulo**	**PK**	**FK**	**UK**	**Nota/Comentarios**	
1	id_producto	Identificador único del producto	INTEGER	6	NO	SI			Dato obligatorio	
2	nombre	Nombre asignado al producto	VARCHAR	30	NO				Ninguno	
3	precio	Precio de venta	INTEGER	8	NO				Ninguno	

5	**Tabla**	**operaciones**	**Descripción Tabla**	**Contiene el registro de las operaciones de venta realizadas por la empresa.**					**Versión**	**1**
#	**Campo**	**Descripción Campo**	**Tipo Dato (Genérico)**	**Tamaño / Longitud**	**Nulo**	**PK**	**FK**	**UK**	**Nota/Comentarios**	
1	id_registro	Identificador único del registro	INTEGER	-	NO	SI			Dato obligatorio	
2	id_departamento	Identificador único del departamento	INTEGER	6	NO		SI		FK hacía departamento	
3	id_municipio	Identificador único del municipio	INTEGER	6	NO		SI		FK hacía municipio	
4	id_producto	Código único del producto	INTEGER	6	NO		SI		FK hacía producto	
5	fecha	Fecha en la que se realizó la venta	DATE	-	NO				Formato de fecha esperado: AAAA-MM-DD	
6	cantidad	Número de unidades vendidas	INTEGER	10	NO				Ninguno	
7	estado	Estado de la operación	VARCHAR	30	NO				Ninguno	

4.- Corrida del algoritmo ETL

En el procedimiento del ETL se puede evidenciar que se extraen datos desde el archivo CSV (colombia-dane-departamentos), que dentro de esta se encuentra gran información de todo el territorio según el DANE y sus respectivos datos.

	A	B	C	D	E	F	G	H
1	REGION|CODIGO DANE DEPARTAMENTO|DEPARTAMENTO|CODIGO DANE MUNICIPIO|MUNICIPIO							
2	Region Eje Cafetero - Antioquia|5|Antioquia|5.001|Medellin							
3	Region Eje Cafetero - Antioquia|5|Antioquia|5.002|Abejorral							
4	Region Eje Cafetero - Antioquia|5|Antioquia|5.004|Abriaqui							
5	Region Eje Cafetero - Antioquia|5|Antioquia|5.021|Alejandria							
6	Region Eje Cafetero - Antioquia|5|Antioquia|5.03|Amaga							
7	Region Eje Cafetero - Antioquia|5|Antioquia|5.031|Amalfi							

Una vez se tenga la conexión con la hoja del DANE tipo csv, se realizar una serie de procesos y líneas de código la cual se da una limpieza correspondiente de los datos, ya que se puede evidenciar datos incorrectos en su contenido, también se evidencia fechas erróneas con un mes “13” y otros procesos el cual se corrigen, por lo que a la final pasamos de datos “crudos” o mal redactados a datos estructurados y de mucha más confiabilidad.

	id_registro integer	id_departamento integer	id_municipio integer	id_producto integer	fecha character varying (10)	cantidad integer	estado character varying (1)
2	10014	5715	5715078	4	2024-12-09	-198	F
3	10225	5725	5725005	2	2024-03-26	0	F
4	10326	0	5715051	3	2024-06-21	105	F
5	10686	5705	5705108	0	2024-06-17	176	F
6	11599	5708	5708013	2	24-02-08	99	F
7	11734	5705	5705108	0	2024-11-09	107	F
8	11907	5715	5715104	2	2024-06-10	-144	F
9	12110	5752	5752012	2	024-07-17	82	F
10	12188	0	5715120	2	2024-05-15	199	F
11	13161	5705	5705008	1	2024-12-15	0	F
12	13945	5713	5713027	3	13-12-2024	182	F
13	14020	0	5723027	3	2024-08-14	103	F
14	14368	5725	5725051	4	24-28-10	147	F
15	15208	5723	5723011	2	2024-11-08	-175	F
16	15412	5719	5719035	4	2024-10-14	0	F
17	15955	5754	5754008	1	24-27-09	160	F
18	16558	5705	5705075	2	01-02-24	122	F
19	16635	0	5741019	3	2024-12-13	84	F
20	17125	5708	5708008	4	12-12-2024	59	F
21	17341	5705	5705108	0	2024-03-17	132	F
22	17528	5719	5719035	3	2024-11-02	0	F
23	18056	5785	5785004	1	24-09-09	86	F
24	18126	5720	5720024	2	2024-02-13	-181	F
25	18469	0	5763011	4	2024-06-20	2	F
26	18911	5705	5705108	0	2024-03-23	126	F
27	19181	5715	5715078	4	2024-12-08	0	F
28	19195	5705	5705108	0	2024-03-15	126	F
29	19538	5754	5754021	1	2024-08-23	-112	F
30	19680	5705	5705102	4	11-23-2024	129	F

por lo que a la final en la carga (load), se ejecutan las consultas y validaciones para poder así dar un óptimo manejo a los datos como puede ser para consultas, análisis, reportes, visualizaciones o cualquier otro uso particular de todos

los datos gracias a que en medio del proceso de extracción, transformación y por último la carga los datos son más confiables y flexibles para su utilización final.

```
1
2   SELECT *FROM operaciones
```

Data Output Messages Notifications

Showing rows: 1 to 1000

	id_registro bigint	id_departamento bigint	id_municipio bigint	id_producto bigint	fecha text	cantidad bigint	estado text
1	10001	5723	23350	2	2024-08-21	180	F
2	10002	5725	25086	2	2024-01-19	133	F
3	10003	5719	19392	3	2024-11-24	182	F
4	10004	5720	20060	3	2024-01-14	69	F
5	10005	5776	76113	4	2024-09-18	55	F
6	10006	5785	85325	2	2024-03-09	73	F
7	10007	5715	15820	4	2024-03-08	116	F
8	10008	5715	15276	1	2024-12-19	60	F

5- Modificar el algoritmo ETL para incluir datos de región.

Para la creación de la tabla “region” se asignan dos atributos; “id_region” como clave primaria y de tipo serial y “nombre_region” tipo varchar. Al ejecutar el script se verifica la creación de dicha tabla sin inconvenientes y lista para la carga de datos.

```
--Creacion de la tabla región
CREATE TABLE public.region (
    id_region SERIAL PRIMARY KEY,
    nombre_region VARCHAR(50) UNIQUE
);

SELECT * FROM region
```

Data Output | Messages | Notifications

id_region [PK] integer	nombre_region character varying (50)

Para la carga de esta tabla se utilizan los datos asignados al campo “region” de la tabla temporal. Se aprovecha la herramienta “DISTINTC” para que recorra todos y cada uno de las regiones y nos de una lista completa sin repetir valores. Encontramos un total de 6 regiones.

```
SELECT * FROM region

--Carga de datos a la tabla "region" usando los valores del campo "region" en la tabla temporal
INSERT INTO public.region (nombre_region)
SELECT DISTINCT region
FROM public.temporal
WHERE region IS NOT NULL;
```

Data Output | Messages | Notifications

Showing rows: 1 to

	id_region [PK] integer	nombre_region character varying (50)
1	1	Region Eje Cafetero - Antioquia
2	2	Region Centro Oriente
3	3	Region Centro Sur
4	4	Region Caribe
5	5	Region Llano
6	6	Region Pacifico

Finalmente, para relacionar la tabla "operaciones" con información geográfica de la región se procede con la siguiente estrategia:

```
169 SELECT * FROM operaciones
```

Data Output Messages Notifications

Showing rows: 1 to 1000 Page No: 1

	id_registro integer	id_departamento integer	id_municipio integer	id_producto integer	fecha character varying (10)	cantidad integer	estado character varying (1)	id_region integer
1	10001	5723	5723009	2	2024-8-21	180	F	4
2	10002	5725	5725007	2	2024-01-19	133	F	2
3	10003	5719	5719016	3	2024-11-24	182	F	6

1. Se realiza un enlace de datos agregando el campo "id_region" a las tablas "operaciones" y "municipio" así poder segmentar las ventas por regiones.

```
113 -- Agregamos la columna id_region a la tabla de operaciones
114 ALTER TABLE public.operaciones
115 ADD COLUMN id_region INT;
116
117 -- Luego hacemos lo mismo para municipios
118 ALTER TABLE public.municipios
119 ADD COLUMN id_region INT;
```

2. Para poblar esta columna se realizó una unión con la tabla "municipios" y para aprovechar que cada registro de venta ya contaba con un "id_municipio", se trasladó el código de región correspondiente a cada una de las transacciones. De esta manera, cada venta queda categorizada según la región donde fue realizada.

```
146 UPDATE public.operaciones o
147 SET id_region = m.id_region
148 FROM public.municipios m
149 WHERE o.id_municipio = m.id_municipio;
```

Data Output Messages Notifications

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-1
Profesor: Pablo A. Deossa M.

6.- Detectar registros con problemas. Transformación de datos (limpieza, modificación, imputación)

Tipo de problema	Número Registro	Campo (BD)	Problema detectado	Solución
A	10001	fecha	Formato: 2024-8-21	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	11599	fecha	Formato: 24-02-08	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	12110	fecha	Formato: 024-07-17	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	13945	fecha	Formato: 13-12-2024	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	14368	fecha	Formato: 24-28-10	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	15955	fecha	Formato: 24-27-09	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	16558	fecha	Formato: 01-02-24	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	17125	fecha	Formato: 12-12-2024	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	18056	fecha	Formato: 24-09-09	df['fecha_dt'].dt.strftime('%Y-%m-%d')
A	19680	fecha	Formato: 11-23-2024	df['fecha_dt'].dt.strftime('%Y-%m-%d')
B	10225	cantidad	cantidad = 0	Calcular promedio y asigna = .map(promedios_municipio)
B	13161	cantidad	cantidad = 0	Calcular promedio y asigna = .map(promedios_municipio)
B	15412	cantidad	cantidad = 0	Calcular promedio y asigna = .map(promedios_municipio)
B	17528	cantidad	cantidad = 0	Calcular promedio y asigna = .map(promedios_municipio)
B	19181	cantidad	cantidad = 0	Calcular promedio y asigna = .map(promedios_municipio)
C	10014	cantidad	Valor negativo: -198	Eliminar negativo - df['cantidad'].abs()
C	11907	cantidad	Valor negativo: -144	Eliminar negativo - df['cantidad'].abs()
C	15208	cantidad	Valor negativo: -175	Eliminar negativo - df['cantidad'].abs()
C	18126	cantidad	Valor negativo: -181	Eliminar negativo - df['cantidad'].abs()
C	19538	cantidad	Valor negativo: -112	Eliminar negativo - df['cantidad'].abs()
D	10326	id_departamento	id_departamento = 0	df.loc[filtro_d, 'id_municipio'].astype(str).str[:4]
D	12188	id_departamento	id_departamento = 0	df.loc[filtro_d, 'id_municipio'].astype(str).str[:4]
D	14020	id_departamento	id_departamento = 0	df.loc[filtro_d, 'id_municipio'].astype(str).str[:4]
D	16635	id_departamento	id_departamento = 0	df.loc[filtro_d, 'id_municipio'].astype(str).str[:4]
D	18469	id_departamento	id_departamento = 0	df.loc[filtro_d, 'id_municipio'].astype(str).str[:4]
E	10686	id_producto	id_producto = 0	df.loc[filtro_e, 'id_producto'] = id_naranjita
E	11734	id_producto	id_producto = 0	df.loc[filtro_e, 'id_producto'] = id_naranjita
E	17341	id_producto	id_producto = 0	df.loc[filtro_e, 'id_producto'] = id_naranjita
E	18911	id_producto	id_producto = 0	df.loc[filtro_e, 'id_producto'] = id_naranjita
E	19195	id_producto	id_producto = 0	df.loc[filtro_e, 'id_producto'] = id_naranjita

7.- Tabla de consultas SQL

Creación de la vista y verificación del proceso de limpieza de datos para vista_operaciones

#	Descripción	Consulta SQL
7.1	**Seleccionar los 8 departamentos con mayor *volumen* de ventas (monto) de productos ordenados de mayor a menor.** Datos solicitados: nombre de departamento y monto total por departamento de todos los productos. Nota: Recuerde que tiene agrupar por departamento	Script SQL - Consulta 7.1
7.2	**Seleccionar los 15 municipios con mayor *cantidad* de productos vendidos en el departamento de Antioquia ordenados de mayor a menor.** Datos solicitados: nombre municipio y cantidad total por municipio. Nota: Recuerde que tiene agrupar por municipio	Script SQL - Consulta 7.2
7.3	**Seleccionar los 5 departamentos con mayor cantidad de gaseosas vendidas del producto "MANZALOCA" ordenados de mayor a menor.** Datos solicitados: nombre de departamento y cantidad total por departamento. Nota: Recuerde que tiene agrupar por departamento y filtrar por el producto.	Script SQL - Consulta 7.3
7.4	**Seleccione los 5 municipios con el menor monto de ventas de gaseosas ordenados de menor a mayor.** Datos solicitados: nombre del departamento al que pertenece, nombre municipio y monto total de ventas por municipio. Nota: Recuerde que tiene agrupar por municipio	Script SQL - Consulta 7.4
7.5	**Consultar la cantidad de gaseosas vendidas de cada producto por cada región ordenados de mayor a menor.**	Script SQL - Consulta 7.5
7.6	**Consultar el total del monto de ventas de cada producto en Antioquia de mayor a menor.**	Script SQL - Consulta 7.6

8.- Gráficos

8.1.- Gráfico de Pareto que muestra los resultados de la consulta #7.1.

8.1.1.- Resultados de la consulta.

	departamento text	monto_total numeric
1	NORTE DE SANTAND...	106641400
2	ANTIOQUIA	105759800
3	BOYACÁ	99513900
4	CUNDINAMARCA	93349300
5	NARIÑO	54167600
6	BOLÍVAR	40279200
7	TOLIMA	39817700
8	VALLE DEL CAUCA	36605600

8.1.2.- Gráfico.

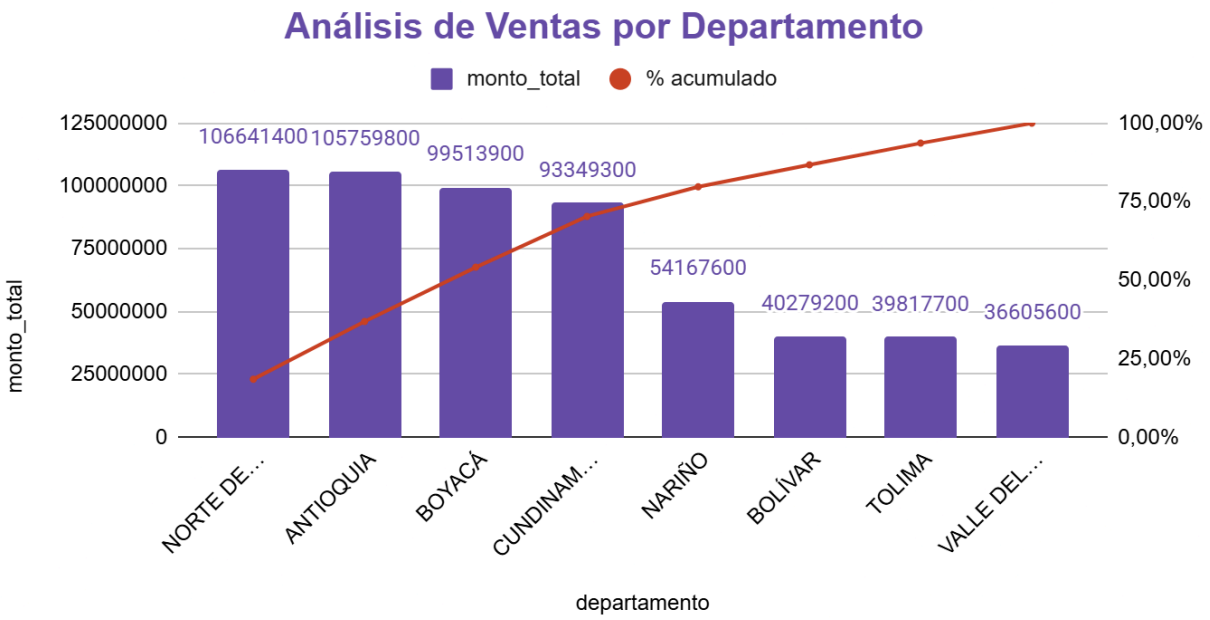

8.2.- Gráfico de Pareto que muestra los resultados de la consulta #7.2.

8.2.1.- Resultados de la consulta.

	municipio text	cantidad_total numeric
1	VALDIVIA	1850
2	TURBO	1708
3	SOPETRAN	1699
4	NARINO	1611
5	CACERES	1604
6	AMAGA	1600
7	FRONTINO	1520
8	PUERTO BERRIO	1514
9	ANORI	1510
10	DABEIBA	1441
11	AMALFI	1430
12	BELMIRA	1412
13	SAN PEDRO DE URA...	1399
14	VENECIA	1391
15	ARBOLETES	1380

8.2.2.- Gráfico.

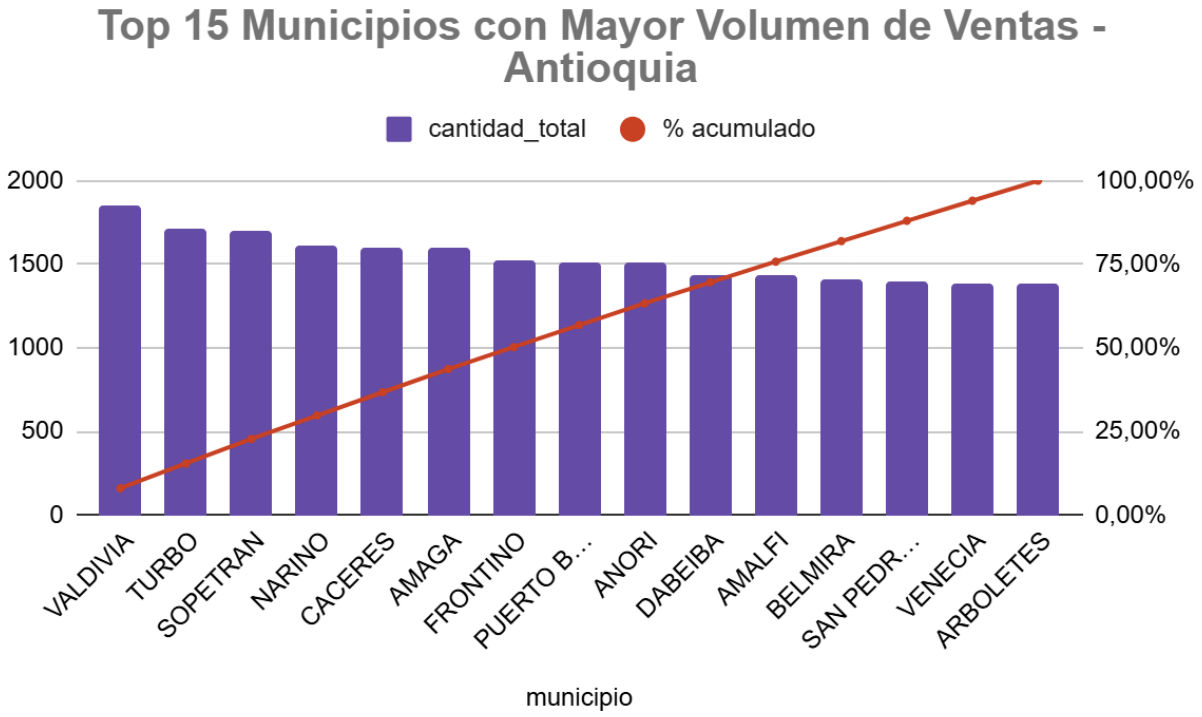

8.3.- Gráfico de Pareto que muestra los resultados de la consulta #7.3.

8.3.1.- Resultados de la consulta.

	departamento text	cantidad_total numeric
1	NORTE DE SANTAND...	30160
2	ANTIOQUIA	27305
3	BOYACÁ	26577
4	CUNDINAMARCA	25510
5	NARIÑO	14273

8.3.2.- Gráfico.

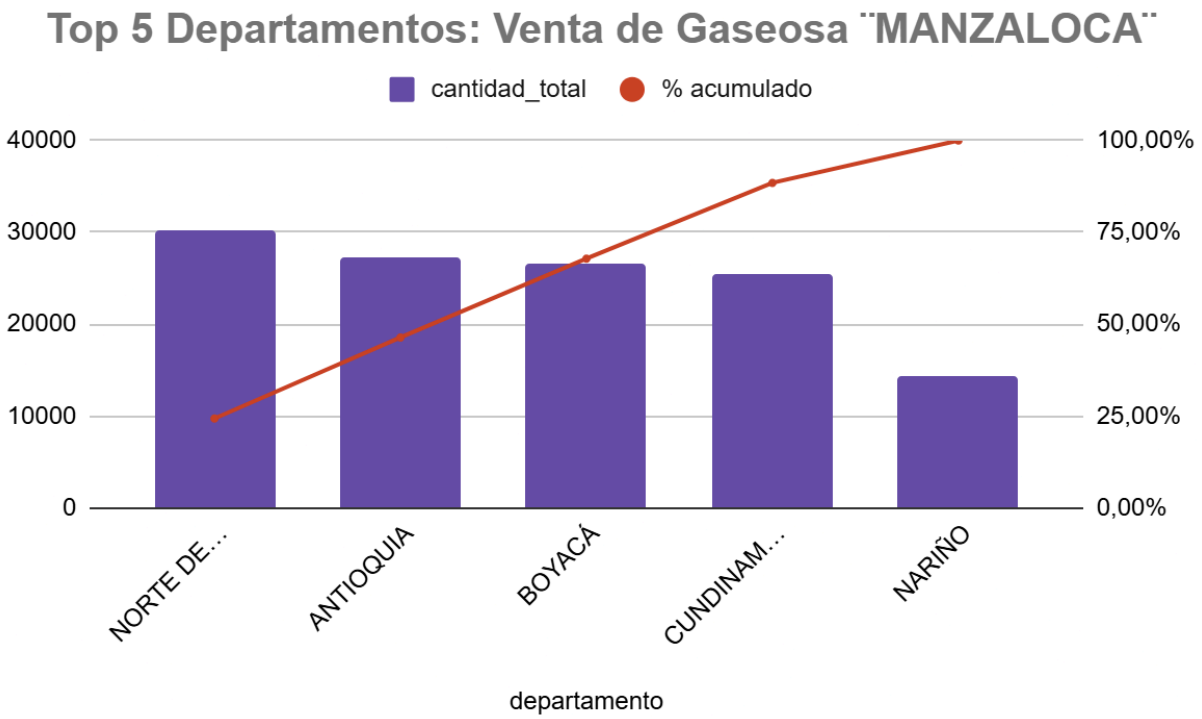

8.4.- Gráfico de Pareto que muestra los resultados de la consulta #7.4.

8.4.1.- Resultados de la consulta.

	departamento text	municipio text	monto_total numeric
1	VALLE DEL CAU...	ZARZAL	68200
2	CESAR	PELAYA	86400
3	BOYACÁ	Togüí	92800
4	CÓRDOBA	MONITOS	94200
5	CUNDINAMARCA	SESQUILE	104200

8.4.2.- Gráfico.

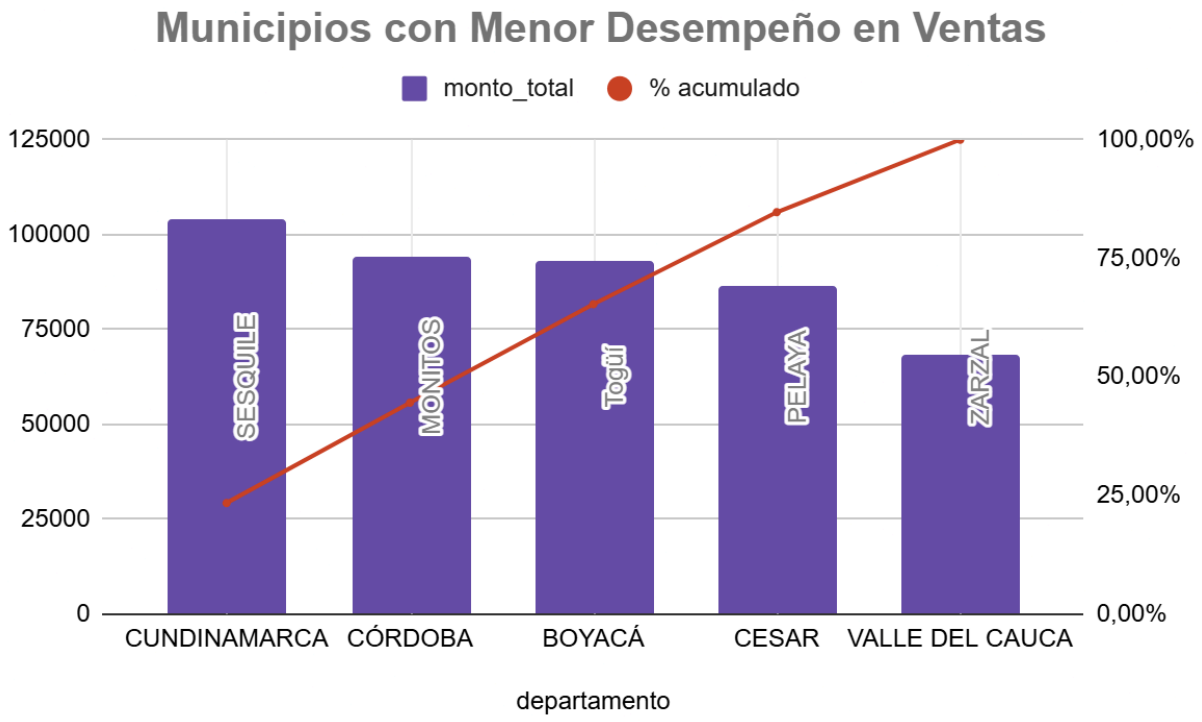

8.5.- Gráfico de Tortas que muestra los resultados de la consulta #7.5.

8.5.1.- Resultados de la consulta.

	id_region bigint	region character varying (50)	producto character varying (20)	cantidad_total numeric
1	2	Region Centro Oriente	MANGOSON	83105
2	2	Region Centro Oriente	MANZALOCA	82590
3	2	Region Centro Oriente	NARANJITA	82514
4	2	Region Centro Oriente	COLOMBIANITA	78059
5	4	Region Caribe	NARANJITA	47274
6	4	Region Caribe	COLOMBIANITA	44702
7	4	Region Caribe	MANGOSON	44699
8	6	Region Pacifico	MANGOSON	43859
9	6	Region Pacifico	COLOMBIANITA	42949
10	4	Region Caribe	MANZALOCA	42727
11	1	Region Eje Cafetero - Antioq...	COLOMBIANITA	41966
12	1	Region Eje Cafetero - Antioq...	NARANJITA	41405
13	6	Region Pacifico	NARANJITA	39984
14	6	Region Pacifico	MANZALOCA	39871
15	1	Region Eje Cafetero - Antioq...	MANGOSON	39231
16	1	Region Eje Cafetero - Antioq...	MANZALOCA	38089
17	3	Region Centro Sur	NARANJITA	29775
18	3	Region Centro Sur	MANZALOCA	28327
19	3	Region Centro Sur	MANGOSON	28248
20	3	Region Centro Sur	COLOMBIANITA	27858
21	5	Region Llano	MANZALOCA	16444
22	5	Region Llano	NARANJITA	15595
23	5	Region Llano	COLOMBIANITA	14430
24	5	Region Llano	MANGOSON	14054

8.5.2.- Gráfico.

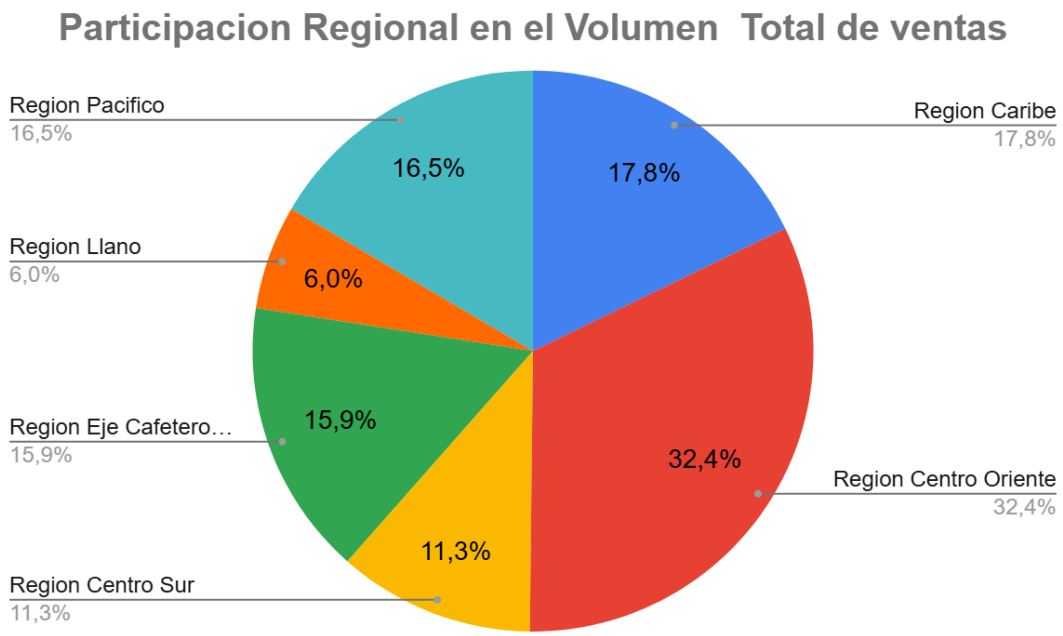

8.6.- Gráfico de Torta que muestra los resultados de la consulta #7.6.

8.6.1.- Resultados de la consulta.

	producto character varying (20)	monto_total numeric
1	COLOMBIANITA	35680800
2	MANZALOCA	27305000
3	MANGOSON	24820200
4	NARANJITA	17953800

8.6.2.- Gráfico.

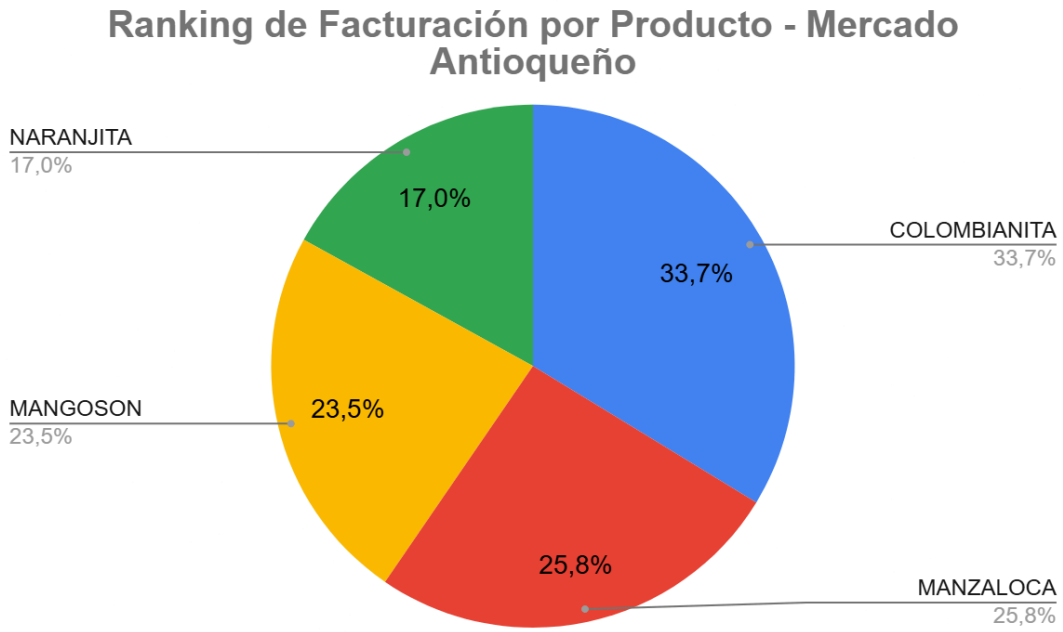

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-1
Profesor: Pablo A. Deossa M.

10.- Determinar el tiempo y tamaño de procesamiento de un conjunto de registros.

Cantidad de registros	Tiempo de procesamiento	Tamaño tabla "tamanio"	Tamaño Base de Datos "bigdata"	Porcentaje de almacenamiento de "tamanio" con respecto al total de la base de datos
10.000	103 ms	704 KB	10373 KB	6.71 %
100.000	319 ms	6704 KB	16381 KB	39.23 %
1.000.000	3012 ms	66720 KB	76397 KB	80.29 %
10.000.000	23841 ms	666864 KB	676549 KB	89.72 %

Script SQL - Registros 10000

Script SQL - Registros 100000

Script SQL - Registros 1000000

Script SQL - Registros 10000000

11.- Análisis de los resultados

ANÁLISIS DE RESULTADOS Y RECOMENDACIONES PARA LA TOMA DE DECISIONES

A partir del análisis de los datos de ventas obtenidos mediante las consultas realizadas sobre la vista_operaciones, fue posible identificar patrones importantes en el comportamiento comercial de la empresa en diferentes departamentos, municipios, regiones y productos. Estos resultados permiten comprender cómo se distribuyen las ventas y detectar oportunidades de mejora en la estrategia comercial.

El análisis evidenció que algunos departamentos concentran un mayor volumen de ventas, lo que puede estar relacionado con factores como la densidad poblacional, la actividad económica y una mayor presencia de puntos de venta. Este comportamiento indica que la empresa tiene una mayor penetración de mercado en estos territorios, por lo que se recomienda fortalecer la estrategia comercial en dichas zonas mediante campañas de fidelización, promociones y asegurando una adecuada disponibilidad de productos.

Por otro lado se identificaron departamentos y municipios con niveles de ventas significativamente menores. Esta situación podría deberse a una menor cobertura de distribución, baja presencia comercial o menor demanda del producto. En estos casos se recomienda analizar con mayor detalle las causas del bajo desempeño y considerar estrategias que permitan mejorar la presencia de la marca en estas regiones.

Asimismo el análisis por producto mostró que algunos productos tienen mayor aceptación en determinadas regiones, lo que evidencia diferencias en las preferencias de consumo. Esta información es valiosa para la empresa, ya que permite adaptar la estrategia de distribución y promoción de los productos según las características del mercado en cada región.

Finalmente también se detectaron algunos municipios con comportamientos de venta fuera de lo esperado, lo cual puede indicar la presencia de datos atípicos o situaciones particulares del mercado. Estos casos deben analizarse con mayor profundidad para determinar si se deben a factores comerciales, logísticos o a eventos específicos que influyeron en el comportamiento de las ventas.

En conclusión, el análisis de los datos permite identificar oportunidades para mejorar la estrategia comercial de la empresa, optimizar la distribución de los productos y tomar decisiones basadas en información objetiva. El uso de herramientas de análisis de datos resulta fundamental para comprender el comportamiento del mercado y apoyar la toma de decisiones estratégicas dentro de la organización.

12.- Diagrama de flujo del programa Python de procesamiento ETL.

Diagrama de flujo del ETL para la carga de datos en la tabla “municipios” y tabla “departamentos”.

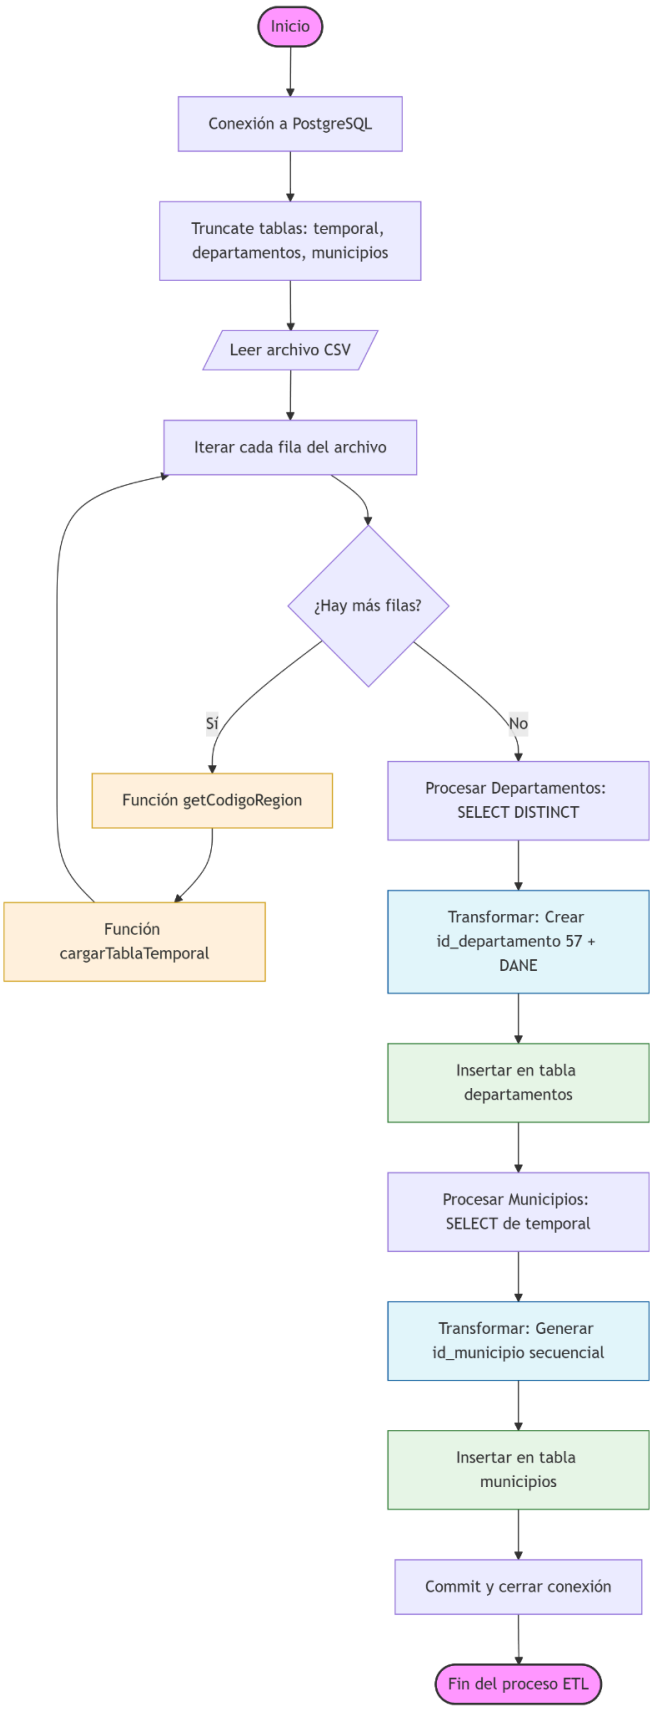

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 0100
Periodo 2026-1
Profesor: Pablo A. Deossa M.

Diagrama de flujo del ETL para la carga del campo “poblacion” de la tabla “municipios”

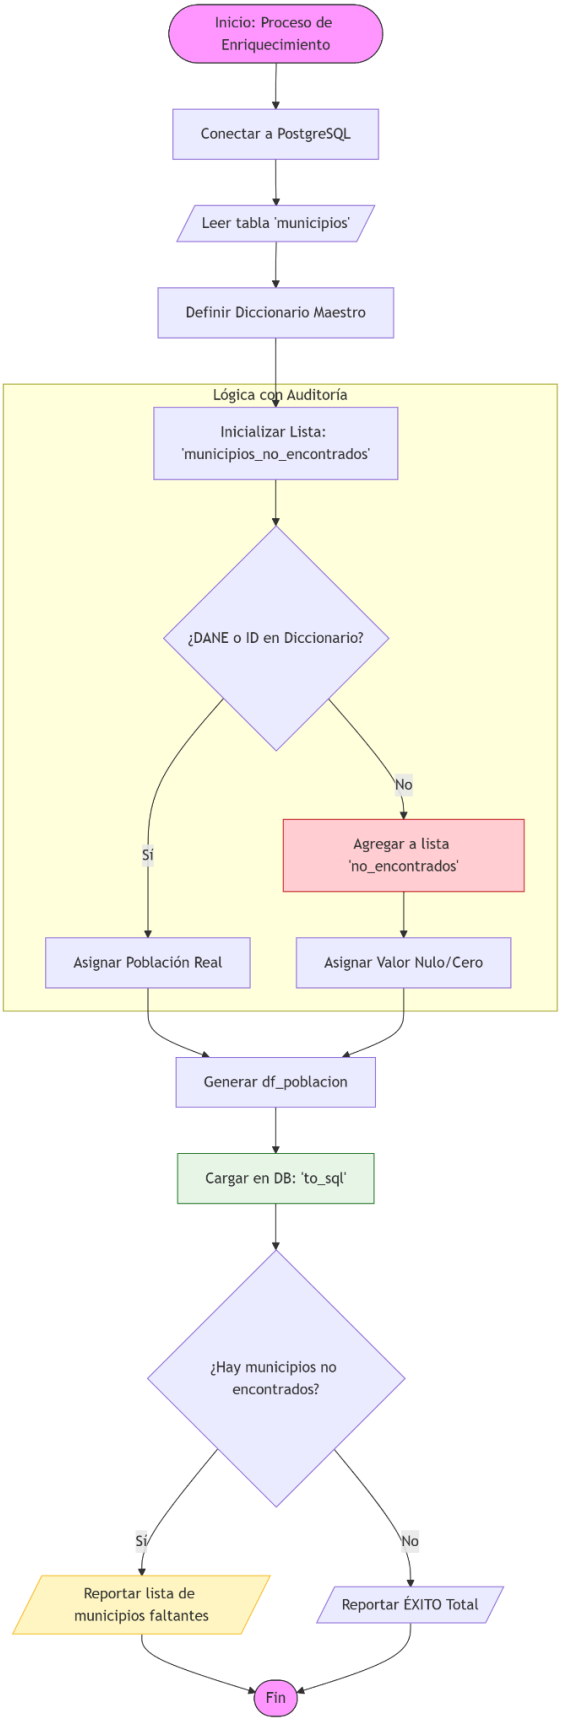

13.- Conclusiones INDIVIDUALES

Juan Felipe Serna Bedoya: Por medio de este trabajo se pudo evidenciar la importancia de un análisis preliminar completo de la situación, las reglas de negocio y los datos disponibles. Esto, seguido de una secuencia de desarrollo e implementación adecuada, permitió dar robustez e integridad referencial a la base de datos.

Una vez realizado esto, el reto principal fue la carga de grandes volúmenes de información de manera eficiente, lo cual se logró mediante procesos y algoritmos de ETL. Estas herramientas, apoyadas en lenguajes como Python y librerías como Pandas, demostraron ser eficaces para este tipo de tareas. Una vez almacenada la información, el paso crítico fue asegurar su calidad, utilizando las mismas herramientas para detectar y corregir errores de acuerdo con las reglas de negocio previamente establecidas.

Cabe aclarar que toda esta información no es de gran utilidad si no se formulan las preguntas correctas. Es decir, las consultas realizadas deben representar insights valiosos para el negocio que permitan entender el mercado y tomar decisiones adecuadas para generar cambios reales. Este proyecto fue un excelente ejercicio de iniciación en el mundo del Big Data, demostrando que la manipulación correcta de la información juega un papel fundamental en la industria actual.

Mydshell Stephannia Usuga Arango: el desarrollo de esta actividad permite comprender la importancia del manejo adecuado de los datos dentro de una organización. A través del proceso ETL se puede evidenciar cómo la información proveniente de diferentes fuentes puede ser extraída, transformada y cargada en una base de datos estructurada, lo cual facilita su análisis y permite obtener resultados confiables. En este proceso también permite identificar errores en los datos, como fechas incorrectas o valores inconsistentes, los cuales fueron corregidos durante la fase de limpieza.

Del mismo modo la realización de consultas SQL y la construcción de gráficos ayuda a interpretar el comportamiento de las ventas de los productos en diferentes regiones del país. Este estudio demuestra cómo el uso de herramientas de análisis de datos puede apoyar a la toma de decisiones dentro de una empresa. Desde el punto de vista académico y profesional este trabajo contribuye al fortalecimiento de habilidades en el manejo de bases de datos, análisis de información y trabajo en equipo, aspectos fundamentales para el desarrollo en el área tecnológica.

Cristian Camilo Hernandez López: con el desarrollo de este trabajo se evidencia la implementación completa de ETL en todos sus procesos y subprocesos para un manejo óptimo de una gran cantidad de datos en este caso hipotéticos de una empresa de gaseosas, dando así un manejo de sus datos, transformarlos y dar una visualización general de estos.

Con este claro ejemplo se da a conocer que, con un correcto uso de herramientas, programas y motores de base de datos, podemos desde un comienzo extraer los datos en nuestro caso un archivo CSV y transformarlos o tratarlos para evitar errores, datos incompletos, nulos o no permitidos por nuestro motor de datos y dar como punto final datos y consultas limpias y bien estructuradas para sus consultas.

Por eso todo este tema y todo este trabajo aparte de dar un paso atrás de cómo hacer un paso a paso para manejar los datos nos muestra el cómo en una instancia final se da a conocer los valores o datos

finales sean estadísticos, numéricos o demás para tener mayor control y un seguimiento pleno de gran cantidad de datos extraídos para un uso final.

14.- Video explicativo del desarrollo completo de la tarea por parte de los miembros del equipo

bigdata-et0155-Video-Sustentación-equipo_5